

PROJET DE FIN D'ETUDES

En vue de l'obtention

Du diplôme de Licence d'Excellence

En

Intelligence Artificielle

Sous le thème

**Analyse, conception et implémentation d'un
Système de Recommandation pour le secteur
Hôtelier**

Présenté le 05 Juin 2025 par :

AYAR Hanane

Devant le jury composé de :

Pr. DAIF Abderrahman	Professeur à FSBM	Président
Pr. LOTFI EL Mehdi	Professeur à FSBM	Examineur
Pr. BENTAYEB Hamza	Professeur à FSBM	Examineur
Pr. BOUKHOUMA Adnane	Professeur à FSJES Ain sbaa	Examineur
Pr. MAHROUF Marouane	Professeur à FSBM	Examineur
Pr. ZAKARY Omar	Professeur à FSBM	Encadrant

REMERCIEMENTS

Je tiens à exprimer ma profonde gratitude à toutes les personnes qui ont contribué, de près et de loin, à la réalisation de ce projet de fin d'étude.

*Je remercie tout particulièrement mon encadrant Mr **ZAKARY Omar**, pour sa disponibilité, ses précieux conseils et son soutien tout au long de ce projet. Sa patience et son expertise ont été des atouts inestimables pour mener à bien ce travail.*

*Je souhaite également remercier l'ensemble du corps professoral de la **Faculté des Sciences Ben M'Sik**, pour leur enseignement et leur accompagnement durant toutes ces deux années d'études. Leur savoir et leur passion pour leur discipline ont largement contribué à ma formation et à l'aboutissement de ce projet.*

Je tiens à exprimer ma reconnaissance envers mes camarades de promotion, avec qui j'ai partagé des moments d'entraide et de convivialité, et qui ont été une source constante de motivation.

Enfin, je voudrais adresser un merci spécial à ma famille et à mes amis pour leur soutien indéfectible, leur encouragement et leur compréhension durant cette période exigeante.

À toutes et à tous, je vous dis merci.

RESUME

Dans un monde où l'information abonde et où les choix sont de plus en plus diversifiés, la capacité à recommander des produits ou des services pertinents est devenue essentielle. Ce projet de fin d'études vise à développer une application web de recommandation d'hôtels personnalisée basée sur le contenu des établissements. À partir de données collectées sur Kaggle, nous avons mis en œuvre des algorithmes de vectorisation TF-IDF et de clustering K-Means pour créer des recommandations pertinentes pour les utilisateurs.

L'application, développée avec Streamlit, permet aux utilisateurs de saisir leurs préférences et de recevoir des suggestions d'hôtels qui répondent à leurs besoins spécifiques. La persistance des modèles a été assurée grâce à l'utilisation de Pickle, permettant une exécution rapide et efficace de l'application.

Les résultats montrent une amélioration significative de l'expérience utilisateur en fournissant des recommandations adaptées. Ce travail contribue à enrichir les pratiques de recommandation dans le secteur hôtelier et présente des perspectives intéressantes pour des améliorations futures, telles que l'intégration de techniques de filtrage collaboratif et de systèmes hybrides.

ABSTRACT

In a world where information is abundant and choices are increasingly diversified, the ability to recommend relevant products or services has become essential. This final year project aims to develop a personalized hotel recommendation web application based on the content of hotel establishments. Using data collected from Kaggle, we implemented TF-IDF vectorization and K-Means clustering algorithms to generate relevant recommendations for users.

The application, developed with Streamlit, allows users to input their preferences and receive hotel suggestions that meet their specific needs. Model persistence was ensured using Pickle, enabling fast and efficient application execution.

The results show a significant improvement in user experience by providing tailored recommendations. This work contributes to enhancing recommendation practices in the hotel industry and presents interesting prospects for future improvements, such as integrating collaborative filtering techniques and hybrid systems.

SOMMAIRE

REMERCIEMENTS	1
RESUME.....	2
ABSTRACT	3
SOMMAIRE	4
TABLE DES FIGURES.....	6
INTRODUCTION GENERALE.....	7
1) Problématique :.....	7
2) Objectif :	7
PARTIE I : « Analyse et Conception Théorique ».....	8
1) Vue d'ensemble des Systèmes de Recommandation :.....	9
2) Systèmes de Recommandation Basés sur le Contenu :.....	9
.....	9
a) Principes et Algorithmes :	9
b) Fonctions et Opérations Mathématiques :	9
3) Applications des Systèmes de Recommandation dans l'industrie hôtelière :.....	10
4) Analyse Comparative avec d'Autres Approches de Recommandation :.....	10
PARTIE II : « Fondements Théoriques ».....	11
1) Description des Algorithmes Utilisés :	12
a) Vectorisation TF-IDF :	12
b) Similarité cosinus :	13
c) Clustering K-Means :	14
PARTIE III : « Conception et Architecture du Système »	18
1) Vue d'ensemble du système :	19
2) Choix des bibliothèques :	19
a) Manipulation des Données :	19
b) Machine Learning :	21
c) Persistance du Modèle :	21
d) Création d'Applications Web :	21
3) Flux de données et composants :	21
4) Conception de l'interface utilisateur :	22
PARTIE IV : « Implémentation et résultats ».....	23
1) Description du jeu de données :	24
2) Préparation du Jeu de Données :	24

3)	Prétraitement des Données :.....	24
a)	Nettoyage des Données :	25
b)	Transformation des données :	25
c)	Vectorisation TF-IDF :.....	25
4)	Entraînement du Modèle :.....	26
5)	Utilisation de Pickle pour la Persistance du Modèle :	26
6)	Fonction de recommandation :.....	27
7)	Intégration avec Streamlit :	28
8)	Discussion des résultats :	29
a-	Présentation de l'interface utilisateur.....	29
b-	Exemple de recommandation :.....	31
c-	Valeur ajoutée :	33
CONCLUSION		34

TABLE DES FIGURES

Figure 1: schéma du fonctionnement des systèmes de recommandations basés sur le contenu	9
Figure 2: vectorisation TF-IDF	13
Figure 3: la différence entre la classification et clustering.....	15
Figure 4: initialisation de K.....	16
Figure 5: assignation des points	16
Figure 6: répétition de K-means	17
Figure 7: les logos des bibliothèques utilisés	19
Figure 8: résumé du jeu de données	24
Figure 9: chargement du dataset.....	24
Figure 10: suppression des valeurs nulles	25
Figure 11: suppression des colonnes inutiles	25
Figure 12: suppression des doublons	25
Figure 13: transformation des données	25
Figure 14: importation des bibliothèques nécessaires.....	25
Figure 15: vectorisation TF-IDF	26
Figure 16: création du modèle vectorisation et k-means clustering.....	26
Figure 17: enregistrement du modèle avec Pickle.....	26
Figure 18: fonction de recommandation	27
Figure 19: interface hôtel-IA.....	29
Figure 20: exemple de recommandation	31
Figure 21: 1er résultat de recommandation.....	32
Figure 22: 2ème résultat de recommandation	32

INTRODUCTION GENERALE

Dans un monde où l'information abonde et où les choix sont de plus en plus diversifiés, la capacité à recommander des produits ou des services pertinents est devenue essentielle. Les systèmes de recommandation jouent un rôle crucial dans divers domaines, allant de la vente en ligne à la consommation de contenu numérique, en passant par le secteur hôtelier. Ces systèmes aident non seulement à améliorer l'expérience utilisateur, mais aussi à accroître la satisfaction et la fidélisation des clients.

1) Problématique :

Dans le secteur hôtelier, offrir des recommandations pertinentes et personnalisées est devenu un enjeu majeur pour améliorer l'expérience des clients et augmenter leur satisfaction. Avec la prolifération des options disponibles en ligne, les utilisateurs sont souvent confrontés à une surcharge d'informations, rendant difficile le choix de l'hôtel qui correspond le mieux à leurs préférences et besoins spécifiques. Les systèmes de recommandation actuels, bien qu'efficaces, présentent encore des limitations. Beaucoup d'entre eux se basent principalement sur des approches collaboratives, qui nécessitent une grande quantité de données utilisateur pour être efficaces et peuvent parfois manquer de précision lorsqu'il s'agit de nouveaux utilisateurs ou d'éléments avec peu d'évaluations.

La principale problématique traitée par ce projet est la suivante : **Comment développer un système de recommandation d'hôtels personnalisé, basé sur le contenu des établissements, pour améliorer l'expérience utilisateur et augmenter la satisfaction des clients dans le secteur hôtelier ?**

2) Objectif :

Ce projet de fin d'études vise à développer une application web de recommandation d'hôtels personnalisée, basée sur le contenu des établissements. En utilisant des algorithmes de recommandation basés sur le contenu, nous cherchons à offrir aux utilisateurs des suggestions d'hôtels qui répondent au mieux à leurs préférences et besoins spécifiques.

La partie théorique de ce rapport présentera en détail l'algorithme choisi pour construire un système de recommandation basé sur le contenu, y compris les fonctions mathématiques sous-jacentes et leur mode de fonctionnement. Nous explorerons les techniques utilisées pour analyser et comparer les caractéristiques des hôtels afin de générer des recommandations pertinentes.

Dans la partie pratique, nous décrirons le processus de construction du modèle de recommandation à partir d'un dataset. Cela inclura la collecte et la préparation des données, la mise en œuvre de l'algorithme de recommandation, ainsi que le développement de l'application web. Nous discuterons également des défis rencontrés et des solutions apportées tout au long du projet.

Ce rapport a pour objectif de démontrer la faisabilité et l'efficacité d'un système de recommandation basé sur le contenu dans le secteur hôtelier, en mettant en lumière les aspects théoriques et pratiques de son implémentation.

En conclusion, nous espérons que ce travail contribuera à enrichir les connaissances et les pratiques dans le domaine des systèmes de recommandation, tout en apportant une valeur ajoutée aux utilisateurs et aux prestataires de services hôteliers.

PARTIE I : « Analyse et Conception Théorique

Cette section aborde l'architecture des fondements théoriques de l'algorithme qu'on va utiliser pour ce projet.

1) Vue d'ensemble des Systèmes de Recommandation :

Les systèmes de recommandation sont une sous-classe des systèmes de filtrage d'information qui visent à prédire la note ou la préférence qu'un utilisateur donnerait à un élément. Ces systèmes sont devenus fondamentaux dans diverses applications telles que le commerce électronique, les réseaux sociaux et le streaming de contenu.

2) Systèmes de Recommandation Basés sur le Contenu :

Les systèmes de recommandation basés sur le contenu recommandent des éléments en comparant le contenu des éléments avec le profil des préférences de l'utilisateur. Cette approche utilise les propriétés des éléments précédemment évalués par l'utilisateur pour prédire ses futures préférences.




Figure 1: schéma du fonctionnement des systèmes de recommandations basés sur le contenu

a) Principes et Algorithmes :

Le principe de base du filtrage basé sur le contenu est d'utiliser les caractéristiques des éléments pour recommander d'autres éléments similaires à ceux que l'utilisateur aime, en se basant sur ses interactions passées. Les algorithmes couramment utilisés incluent TF-IDF pour la représentation de texte et la similarité cosinus pour mesurer la similarité entre les éléments.

b) Fonctions et Opérations Mathématiques :

- **Vectorisation TF-IDF:** TF-IDF signifie "Term Frequency-Inverse Document Frequency". C'est une statistique numérique qui reflète l'importance d'un mot dans un document par rapport à une collection de documents (corpus).

$$\text{TF-IDF}(t, d) = \text{TF}(t, d) \times \text{IDF}(t)$$

Où $\text{TF}(t, d)$ est la fréquence du terme t dans le document d , et $\text{IDF}(t)$ est la fréquence

inverse du document pour le terme t .

- **Similarité Cosinus** : Mesure le cosinus de l'angle entre deux vecteurs non nuls. Elle est utilisée pour mesurer la similarité entre deux documents indépendamment de leur taille.

$$\text{Similarité_cosinus}(A,B) = \frac{A \cdot B}{\|A\| \|B\|}$$

- **Clustering K-Means** : Un algorithme qui partitionne un jeu de données en K sous-ensembles distincts et non chevauchants (clusters).

$$\text{Minimiser } \sum^K \sum_{xj \in ci} \|xj - \mu i\|^2$$

Où μ_i est la moyenne des points dans le cluster i .

3) Applications des Systèmes de Recommandation dans l'industrie hôtelière :

Les systèmes de recommandation sont largement utilisés dans l'industrie hôtelière pour personnaliser l'expérience des clients. Ils aident à suggérer des hôtels, des chambres, des commodités et des services en fonction des préférences de l'utilisateur et de son comportement passé.

4) Analyse Comparative avec d'Autres Approches de Recommandation :

Bien que les systèmes basés sur le contenu aient leurs forces, ils sont souvent comparés avec le filtrage collaboratif et les systèmes hybrides. Le filtrage collaboratif, par exemple, fait des recommandations basées sur les interactions utilisateur-élément sans avoir besoin de caractéristiques explicites des éléments. Les systèmes hybrides combinent les deux approches pour tirer parti des forces de chacune.

PARTIE II : « Fondements Théoriques »

Cette partie montre le processus et les fondements théorique et mathématiques pour développer l'algorithme de recommandation utilisé.

1) Description des Algorithmes Utilisés :

Pour développer un système de recommandation d'hôtels personnalisé et efficace, nous avons utilisé plusieurs algorithmes et techniques de traitement des données.

Les principales méthodes employées sont :

- A) **Vectorisation TF-IDF**
- B) **Similarité Cosinus**
- C) **Clustering K-Means**

a) Vectorisation TF-IDF :

La vectorisation TF-IDF est particulièrement utile dans les systèmes de recommandation, en particulier pour le filtrage collaboratif basé sur le contenu. Elle permet de transformer les descriptions des produits, des articles ou tout autre contenu en vecteurs numériques que les algorithmes de recommandation peuvent facilement manipuler pour trouver des éléments similaires.

▪ Utilisation de TF-IDF dans les Systèmes de Recommandation :

1- Représentation des Documents :

- Les éléments du système de recommandation (les noms des hôtels dans notre cas) sont considérés comme des documents.
- Les descriptions de ces éléments (par exemple, caractéristiques des chambres) sont vectorisées en utilisant TF-IDF.

2- Calcul de la Similarité :

- Une fois que chaque document est représenté par un vecteur TF-IDF, on peut calculer la similarité entre les documents.
- La mesure de similarité la plus courante est la similarité cosinus, qui mesure l'angle entre deux vecteurs.

3- Recommandation :

- Pour recommander des éléments similaires à un utilisateur, le système identifie les vecteurs TF-IDF des éléments qu'il a appréciés.
- Le système recherche ensuite les vecteurs TF-IDF similaires parmi tous les éléments disponibles et recommande ceux qui sont les plus similaires.

■ Fondations Mathématiques :




Figure 2: vectorisation TF-IDF

La formule TF-IDF se décompose en deux parties :

- **TF (Term Frequency)** : Le nombre de fois qu'un terme apparaît dans un document, divisé par le nombre total de termes dans le document. Cette mesure indique la fréquence d'un terme dans le document. Cette mesure indique la fréquence d'un terme dans un document donné.

$$TF(t, d) = \frac{\text{Nombre de fois que le terme } t \text{ apparaît dans le document } d}{\text{Nombre total de termes dans le document } d}$$

- **IDF (Inverse Document Frequency)** : La log inverse de la proportion de documents qui contiennent le terme. Cette mesure permet de diminuer le poids des termes courants et d'augmenter celui des termes rares.

$$IDF(t) = \log\left(\frac{\text{Nombre total de documents}}{\text{Nombre de documents contenant le terme } t}\right)$$

La combinaison de TF et IDF donne la formule TF-IDF :

$$TF-IDF(t, d) = TF(t, d) \times IDF(t)$$

La vectorisation TF-IDF transforme un document textuel en un vecteur de poids de termes, facilitant ainsi la comparaison et l'analyse de documents différents.

b) Similarité cosinus :

La similarité cosinus est une mesure utilisée pour déterminer la similitude entre deux vecteurs, souvent utilisée dans le traitement du langage naturel et la recommandation de contenu.

Dans le contexte de la vectorisation TF-IDF, elle permet de mesurer la similitude entre les documents en comparant les vecteurs TF-IDF correspondants.

▪ **Fondations Mathématiques :**

La formule de la similarité cosinus est donnée par :

$$\text{Similarité_cosinus}(A,B) = \frac{A \cdot B}{\|A\| \|B\|}$$

Où $A \cdot B$ est le produit scalaire des vecteurs A et B, et $\|A\|$ et $\|B\|$ sont les normes euclidiennes des vecteurs.

Cette mesure varie de 0 à 1, où 1 indique des vecteurs identiques, 0 indique des vecteurs orthogonaux (aucune similarité), et une valeur intermédiaire indique une certaine similarité.

c) **Clustering K-Means :**

L'algorithme des k-means (ou bien k-moyennes) est l'un des algorithmes d'apprentissage non supervisé les plus simples et les plus populaires. Il permet d'analyser un jeu de données afin de regrouper les données « similaires » en groupes (ou clusters). Ce principe est applicable dans divers domaines de l'industrie comme le domaine du marketing pour la segmentation des clients, analyse des réseaux sociaux, et principalement les systèmes de recommandation. Cela introduit des notions qui se cachent derrière l'algorithme importantes à découvrir et à comprendre :

▪ **Pourquoi utiliser l'algorithme k-means ?**

Avec ce que nous venons de voir, l'algorithme k-means s'adapte à de nombreuses situations de clustering :

- **L'algorithme k-means est un modèle prédictif très simple et non hiérarchique :** il ne nécessite donc pas beaucoup de temps d'exécution. Il est aussi rapide et efficace en termes de coûts de calcul. Cela en fait la solution meilleure dans le cas de données volumineuses.
- **Il ne peut être exécuté qu'avec des données numériques :** Il est donc déconseillé de l'utiliser avec des données d'autres types.
- **Dans la situation où le jeu de données est de grande dimension :** c'est-à-dire lorsque le nombre de variables ou d'attributs est beaucoup plus élevé que le nombre d'observations, un modèle de Machine Learning aura besoin d'un énorme ensemble d'entraînement (train set) pour apprendre. Cet algorithme est le meilleur choix dans ce cas.

Néanmoins, il y a aucune garantie de convergence avec l'algorithme des k-means. En effet, puisque l'étape d'initialisation calcule des centroïdes de manière aléatoire, il ne se peut qu'aucun groupe ne se stabilise à long terme, et donc qu'aucune convergence ne se produise.

L'algorithme des k-means est l'un des algorithmes de **clustering** les plus populaires et généralement la première chose que les Data Scientists appliquent pour résoudre des tâches de **re- groupement**. Il est non seulement simple et facile à comprendre mais aussi rapide et économique en matière de coût de calcul.

▪ **Notion du regroupement (clustering) :**

En Machine Learning, nous devons séparer nos données en groupes pour les comprendre. Il existe deux types de méthodes d'apprentissage :

- **Si les données sont étiquetées :** il s'agit d'une classification, et les données sont re- groupées selon leurs étiquettes (ou labels). On appelle cela l'apprentissage supervisé.
- **Si les données ne sont pas étiquetées :** il s'agit d'un regroupement (clustering). Le principe c'est de séparer les données en groupes homogènes ayant des caractéristiques communes. On appelle cela apprentissage non supervisé.




Figure 3: la différence entre la classification et clustering

Dans le deuxième cas, on cherche à tirer des références à partir des données en utilisant des méthodes et des métriques de son choix. L'algorithme des k-means est donc un exemple d'apprentissage non supervisé.

Le nombre de groupes (clusters) représenté par la variable n'est pas connu : c'est la personne qui est censée le préciser en fonction de son jeu de données, en estimant par lui-même le nombre de groupe qui existerait dans le jeu de données.

▪ **Principe de fonctionnement de l'algorithme k-means :**

L'algorithme K-means identifie un certain nombre de centroïdes dans un ensemble de données, un centroïde étant la moyenne arithmétique de tous les points de données appartenant à un cluster particulier.

L'algorithme attribue ensuite chaque point de données au cluster le plus proche en essayant de maintenir les clusters aussi petits que possible (le terme « means » dans K-means fait référence à la tâche consistant à faire la moyenne des données ou à trouver le centroïde).

En même temps, K-means tente de garder les autres clusters aussi différents que possible. En pratique, il fonctionne comme suit :

- **Initialisation de « K » centres de cluster :**

L'algorithme K-means commence par initialiser « K » centres de cluster de façon aléatoire.




Figure 4: initialisation de K

(Le nombre K est une variable d'entrée et les emplacements peuvent également être donnés en entrée).

- **Assignment des points à un centre de cluster :**




Figure 5: assignation des points

À chaque passage de l'algorithme, on assigne chaque point à son centre de cluster le plus proches.

- **Mise à jour des centres de cluster :**

Les centres des clusters sont ensuite mis à jour pour être les « centres » de tous les points qui lui sont assignés dans ce passage. Cela se fait en recalculant les centres de cluster comme la moyenne des points dans chaque cluster respectif.

- **Répétition de l'algorithme kmeans :**

L'algorithme se répète jusqu'à ce qu'il y ait un changement minimum des centres de cluster par rapport à la dernière itération.




Figure 6: répétition de K-means

- **Les limites de K-Means :**

Malgré ses nombreux avantages, K-Means montre certaines limites, à savoir :

- On ne peut l'utiliser que lorsque l'on peut définir la valeur moyenne du cluster, ce qui peut ne pas convenir à certaines applications ;
- Dans l'algorithme K-means, on donne K à l'avance, et le choix de cette valeur K est très difficile à estimer. Souvent, on ne sait pas à l'avance en combien de catégories on doit diviser un ensemble de données donné ;
- Lorsque l'on veut appliquer l'algorithme K-means, il est d'abord nécessaire de déterminer une partition initiale basée sur le centre de regroupement initial, puis d'optimiser la partition initiale. La sélection de ce centre de clustering initial a un impact plus important sur les résultats du clustering. Si l'on ne sélectionne pas bien la valeur initiale, on risque de ne pas obtenir de résultats de clustering efficaces ;
- L'algorithme doit continuellement ajuster la classification de l'échantillon et calculer continuellement les nouveaux centres de cluster ajustés. Par conséquent, lorsque la quantité de données est très grande, le coût en temps de l'algorithme est très grand ;
- Si le cluster contient des points anormaux, la valeur moyenne déviara sérieusement ;
- Ne conviens pas à la découverte de clusters de formes non convexes ou de clusters de tailles très différentes.

PARTIE III : « Conception et Architecture du Système »

Cette partie vise à présenter une vue d'ensemble de la structure et du fonctionnement du système de recommandation, en décrivant ses composants, le flux de données, et la conception de l'interface utilisateur.

1) Vue d'ensemble du système :

Le système de recommandation d'hôtels est une application web conçue pour fournir des suggestions personnalisées aux utilisateurs en fonction de leurs préférences spécifiques. Le système utilise une combinaison de techniques de machine learning et d'ingénierie logicielle pour offrir une expérience utilisateur optimale. Les principaux composants du système sont :

1. **Interface Utilisateur** : L'interface utilisateur (UI) est construite à l'aide de Streamlit, offrant une interaction simple et intuitive pour les utilisateurs finaux.
2. **Module de Prétraitement des Données** : Ce module prend en charge la collecte, le nettoyage et la préparation des données nécessaires pour entraîner le modèle de recommandation.
3. **Moteur de Recommandation** : Utilise des techniques de vectorisation TF-IDF, de similarité cosinus et de clustering K-Means pour générer des recommandations.
4. **Persistance des Modèles** : Utilisation de Pickle pour sauvegarder et charger les modèles entraînés.
5. **Base de Données** : Stocke les informations sur les hôtels et les préférences des utilisateurs.



Figure 7: les logos des bibliothèques utilisés

2) Choix des bibliothèques :

a) Manipulation des Données :

1. Pandas :

Pandas est une bibliothèque puissante pour la manipulation et l'analyse des données. Elle permet de lire, écrire et traiter des données sous forme de DataFrame, ce qui facilite les opérations de nettoyage et de préparation des données.

✓ **Utilisation** : Chargement des jeux de données, nettoyage et transformation des données.

2. NumPy :

NumPy est une bibliothèque fondamentale pour le calcul scientifique en Python. Elle offre un support pour les tableaux et les matrices, ainsi que des fonctions mathématiques pour les opérations sur ces tableaux.

✓ **Utilisation** : Opérations mathématiques et manipulation des tableaux de données.

b) Machine Learning :

scikit-learn :

scikit-learn est une bibliothèque clé pour l'apprentissage automatique en Python. Elle fournit des outils simples et efficaces pour l'analyse des données et la modélisation prédictive, y compris des algorithmes de machine learning comme la vectorisation TF-IDF, le clustering K-Means et les mesures de similarité cosinus.

- ✓ **Utilisation** : Vectorisation des textes, calcul de similarités, clustering et autres algorithmes de machine learning.

c) Persistance du Modèle :

Pickle :

Pickle est une bibliothèque pour la sérialisation et la désérialisation des objets Python. Elle permet de sauvegarder les modèles entraînés et d'autres objets pour une utilisation future, facilitant ainsi la persistance des modèles de machine learning.

- ✓ **Utilisation** : Sauvegarde et chargement des modèles de machine learning.

d) Création d'Applications Web :

Streamlit :

Streamlit est une bibliothèque permettant de créer des applications web interactives de manière simple et rapide. Elle est idéale pour partager des modèles de machine learning et des visualisations de données sans avoir besoin de connaissances approfondies en développement web.

- ✓ **Utilisation** : Développement de l'interface utilisateur et intégration des modèles de recommandation.

Le choix des bibliothèques mentionnées ci-dessus est crucial pour le développement d'un système de recommandation d'hôtels performant. Chaque bibliothèque joue un rôle spécifique, depuis la manipulation des données avec Pandas et NumPy, l'implémentation des algorithmes de machine learning avec scikit-learn, la persistance des modèles avec Pickle, jusqu'à la création d'une application web interactive avec Streamlit.

3) Flux de données et composants :

Le flux de données dans le système suit plusieurs étapes clés :

1. **Collecte des Données** : Les données des hôtels sont collectées et stockées dans un fichier CSV. Ces données comprennent des informations telles que le nom de l'hôtel,

l'adresse, les coordonnées géographiques, la ville, le pays, les caractéristiques des chambres, l'URL, etc.

2. **Prétraitement des Données** : Les données brutes sont nettoyées et préparées pour l'entraînement du modèle. Cela inclut la transformation des caractéristiques textuelles en vecteurs numériques à l'aide de la vectorisation TF-IDF.
3. **Entraînement du Modèle** : Les vecteurs TF-IDF sont utilisés pour entraîner un modèle de clustering K-Means, qui regroupe les hôtels en clusters basés sur leurs caractéristiques. La similarité cosinus est utilisée pour mesurer la similarité entre les préférences des utilisateurs et les caractéristiques des hôtels.
4. **Interface Utilisateur** : Les utilisateurs interagissent avec l'application via une interface web construite avec Streamlit. Ils peuvent entrer leurs préférences et obtenir des recommandations d'hôtels personnalisées.
5. **Processus de sauvegarde des Modèles** : Les modèles entraînés (TF-IDF et K-Means) sont sauvegardés à l'aide de Pickle pour une utilisation ultérieure, permettant de recharger les modèles sans avoir à les réentraîner à chaque exécution.
6. **Recommandation** : Lorsqu'un utilisateur entre ses préférences, le système utilise les modèles sauvegardés pour calculer les similitudes et fournir une liste d'hôtels recommandés.

4) Conception de l'interface utilisateur :

L'interface utilisateur de l'application est construite avec Streamlit, une bibliothèque Python facile à utiliser pour créer des applications web interactives. Voici les principales fonctionnalités de l'interface :

1. **Accueil** : Page d'accueil présentant le système et ses fonctionnalités.
2. **Sélection de la Ville et du Pays** : Des menus déroulants permettent aux utilisateurs de choisir la ville et le pays de leur destination.
3. **Sélection des Préférences** : Une liste de cases à cocher pour que les utilisateurs puissent indiquer leurs préférences spécifiques concernant les caractéristiques des chambres.
4. **Affichage des Recommandations** : Présentation des hôtels recommandés sous forme de liste, avec des informations détaillées sur chaque hôtel, telles que le nom, l'adresse et les caractéristiques.
5. **Filtrage et Tri** : Options permettant aux utilisateurs de filtrer et de trier les résultats selon différents critères (par exemple, par évaluation, distance, etc.).
6. **Bouton de Recommandation** : Un bouton permettant de déclencher le processus de recommandation et d'afficher les résultats directement sur la page.
7. **Affichage de la note de chaque hôtel** : scrapping en temps réel de la note d'hôtel à partir des sites web **Booking** et **Agoda**.
8. **Affichage des commentaires sur chaque hôtel** : scrapping en temps réel des commentaires pour chaque hôtel à partir des sites web **Booking** et **Agoda**.

L'interface est conçue pour être intuitive et réactive, offrant une expérience utilisateur fluide et agréable. L'utilisation de Streamlit permet également d'itérer rapidement et améliorer l'application en fonction des retours des utilisateurs.

PARTIE IV : « Implémentation et résultats »

La partie « implémentation et résultats » concerne l'implémentation des différentes parties du code du projet, ainsi que l'affichage et la discussion des résultats.

1) Description du jeu de données :

Le dataset nommé **hotel recommendation** est utilisé provient de Kaggle. Il contient 4 fichiers csv ,55 colonnes,145425 valeur avec 96203 valeurs uniques.comprenant les attributs suivants :

Summary		
▼	4 files	
	.csv	4
▼	55 columns	
	String	17
	Integer	12
	Decimal	9
	Other	17

- Hotelname : les noms des hôtels.
- Address : l'adresse complète des hôtels existent.
- City : la ville où ils se trouvent.
- Country : le pays d'hôtel.
- Starrating : le nombre des étoiles.
- Roomamenities : les caractéristiques des chambres.
- Roomtype : le type de chaque chambre.
- URL : le lien de booking ou agoda.

Figure 8: résumé du jeu de données

Et ainsi d'autres attributs.

2) Préparation du Jeu de Données :

La première étape de l'implémentation consiste à préparer et charger le jeu de données.

Les données des hôtels sont collectées et stockées dans un fichier CSV. Chaque ligne du fichier représente un hôtel et contient des informations telles que le nom de l'hôtel, l'adresse, la ville, le pays, les caractéristiques des chambres, l'URL, etc.

```
#chargement de jeu de données
hotel_details = pd.read_csv('data/Hotel_details.csv')
hotel_rooms=pd.read_csv('data/Hotel_Room_attributes.csv',delimiter=',')
hotel_cost=pd.read_csv('data/hotels_RoomPrice.csv',delimiter=',')
```

Figure 9: chargement du dataset

3) Prétraitement des Données :

Les données brutes sont nettoyées et transformées pour être utilisées dans le modèle de recommandation. Les étapes de prétraitement incluent :

a) Nettoyage des Données :

Suppression des valeurs manquantes, correction des erreurs typographiques, normalisation des champs de texte, etc.

```
#suppression des valeurs nulles
hotel_details=hotel_details.dropna()
hotel_rooms=hotel_rooms.dropna()
```

Figure 10: suppression des valeurs nulles

```
#suppression des colonnes non nécessaires:
del hotel_details['id']
del hotel_rooms['id']
del hotel_details['zipcode']
```

Figure 11: suppression des colonnes inutiles

```
#suppression des doublants
hotel_details.drop_duplicates(subset='hotelid',keep=False,inplace=True)
```

Figure 12: suppression des doublons

b) Transformation des données :

Combinaison des fichiers csv pour l'obtention d'une seul dataset, avec la fonction merge.

```
#joindre les deux jeux de données 'hotel_details' et 'hotel_rooms':
hotel=pd.merge(hotel_rooms,hotel_details,left_on='hotelcode',right_on='hotelid',how='inner')
```

Figure 13: transformation des données

c) Vectorisation TF-IDF :

Transformation des caractéristiques textuelles des hôtels en vecteurs numériques à l'aide de la technique TF-IDF (Term Frequency-Inverse Document Frequency).

```
import pandas as pd
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.cluster import KMeans
import nltk # type: ignore
import pickle
```

Figure 14: importation des bibliothèques nécessaires

```
# Create a TF-IDF vectorizer
vectorizer = TfidfVectorizer(stop_words=stopwords.words('english'))
tfidf_matrix = vectorizer.fit_transform(df['combined_text'])
```

Figure 15: vectorisation TF-IDF

4) Entraînement du Modèle :

Les vecteurs TF-IDF sont utilisés pour entraîner un modèle de clustering K-Means. Ce modèle regroupe les hôtels en clusters basés sur leurs caractéristiques, facilitant ainsi la recherche des hôtels les plus similaires aux préférences de l'utilisateur.

```
# Create a TF-IDF vectorizer
vectorizer = TfidfVectorizer(stop_words=stopwords.words('english'))
tfidf_matrix = vectorizer.fit_transform(df['combined_text'])

# Apply K-Means clustering
num_clusters = 5
kmeans = KMeans(n_clusters=num_clusters, random_state=42)
kmeans.fit(tfidf_matrix)
df['cluster'] = kmeans.labels_
```

Figure 16: création du modèle vectorisation et k-means clustering

5) Utilisation de Pickle pour la Persistance du Modèle :

Pour éviter de réentraîner les modèles à chaque exécution de l'application, les modèles entraînés (TF-IDF et K-Means) sont sauvegardés à l'aide de Pickle. Lors de l'exécution de l'application, les modèles sauvegardés sont chargés en mémoire, permettant ainsi de générer des recommandations rapidement et efficacement.

```
# Save the vectorizer, kmeans model, and dataframe using pickle
with open('vectorizer.pkl', 'wb') as f:
    pickle.dump(vectorizer, f)

with open('kmeans.pkl', 'wb') as f:
    pickle.dump(kmeans, f)

with open('hotels_df.pkl', 'wb') as f:
    pickle.dump(df, f)
```

Figure 17: enregistrement du modèle avec Pickle

6) Fonction de recommandation :

La fonction `recommend_hotels` recommande les meilleurs hôtels à un utilisateur en fonction de :

- Ses préférences textuelles,
- Une plage de prix souhaitée,
- Et un clustering (groupement) de type KMeans.

❖ Techniques utilisées :

- **TF-IDF** : pour vectoriser le texte utilisateur et les descriptions des hôtels.
- **KMeans** : pour identifier le **cluster** d'hôtels correspondant à l'utilisateur.
- **Similarité cosinus** : pour mesurer la **proximité sémantique** entre la requête et les hôtels.

❖ Étapes principales :

1. Vérifie si des hôtels sont disponibles dans la ville.
2. Transforme la requête utilisateur en vecteur numérique.
3. Prédit le **cluster** le plus approprié avec KMeans.
4. Filtre les hôtels du **même cluster** et dans la **plage de prix**.
5. Calcule la **similarité cosinus** entre la requête et chaque hôtel filtré.
6. Trie les résultats par similarité décroissante.
7. Retourne les **Top N recommandations**.

```
def recommend_hotels(user_preferences, df_to_filter, vectorizer_model, kmeans_model, price_filter_range, top_n=5):
    if df_to_filter.empty or vectorizer_model is None or kmeans_model is None:
        return pd.DataFrame()

    min_price, max_price = price_filter_range
    user_tfidf = vectorizer_model.transform([user_preferences])
    user_cluster = kmeans_model.predict(user_tfidf)[0]

    cluster_hotels = df_to_filter[
        (df_to_filter['cluster'] == user_cluster) &
        (df_to_filter['price'] >= min_price) &
        (df_to_filter['price'] <= max_price)
    ].copy() # Use .copy() to avoid SettingWithCopyWarning

    if cluster_hotels.empty:
        return pd.DataFrame()

    cluster_tfidf_matrix = vectorizer_model.transform(cluster_hotels['combined_text'])
    cosine_sim = cosine_similarity(user_tfidf, cluster_tfidf_matrix)
    sim_scores = list(enumerate(cosine_sim[0]))
    sim_scores = sorted(sim_scores, key=lambda x: x[1], reverse=True)
    hotel_indices = [i[0] for i in sim_scores[:top_n]]

    return cluster_hotels.iloc[hotel_indices].copy()
```

Figure 18: fonction de recommandation

7) Intégration avec Streamlit :

L'application « Hôtel-IA » est développée avec **Streamlit**, une bibliothèque Python conçue pour créer des interfaces web interactives de manière rapide et efficace. Elle offre une **expérience utilisateur fluide**, intuitive et responsive, facilitant la recherche d'hôtels personnalisée selon les préférences de chaque utilisateur.

7.1. Saisie des préférences

L'utilisateur interagit avec l'application à travers une interface simple, où il peut :

- Sélectionner une ville à visiter,
- Choisir ses préférences,
- Définir une plage de prix à l'aide d'un slider interactif.

Ces informations sont ensuite utilisées pour déclencher le moteur de recommandation.

7.2. Moteur de recommandation intelligent

La logique de recommandation repose sur une fonction appelée *recommender*, qui combine plusieurs techniques d'intelligence artificielle :

- Vectorisation du texte utilisateur avec TF-IDF,
- Clustering KMeans pour identifier le groupe d'hôtels le plus proche du profil utilisateur,
- Filtrage par plage de prix pour respecter les contraintes budgétaires,
- Calcul de similarité cosinus pour comparer la description utilisateur aux descriptions des hôtels disponibles,
- Tri des résultats pour extraire les Top N hôtels les plus pertinents.

Ce moteur permet une personnalisation fine des recommandations, même pour des requêtes complexes en langage naturel.

7.3. Intégration en temps réel des notes et avis

Afin d'améliorer la pertinence et la crédibilité des recommandations, l'application intègre une **phase de scraping en temps réel** :

- Les **notes utilisateurs** et **avis récents** sont extraits automatiquement depuis **Booking.com** et **Agoda**,
- Ces données enrichissent chaque fiche hôtel en apportant des informations objectives et actuelles sur :
 - La **note globale** (ex. : 8.7/10),
 - Les **commentaires clients**,
 - D'éventuelles **notes spécifiques** (propreté, emplacement, rapport qualité/prix...).

Cette fonctionnalité permet à l'utilisateur de faire des choix éclairés en se basant sur des

sources fiables et actualisées.

7.4. Affichage des recommandations

Les résultats sont présentés de manière claire et attractive :

- Chaque hôtel recommandé affiche son **nom, description, prix, note Booking/Agoda**, un **extrait d'avis client** et le lien de **Booking/Agoda**,
- L'utilisateur peut comparer facilement les options et identifier celle qui correspond le mieux à ses attentes.

8) Discussion des résultats :

a- Présentation de l'interface utilisateur

L'interface de notre système de recommandation d'hôtels a été conçue pour offrir une expérience simple et intuitive à l'utilisateur. Elle permet de saisir facilement ses préférences et d'obtenir des recommandations personnalisées.

Fonctionnalités principales :

- ✓ Choisir le pays et la ville à visiter,
- ✓ Choisir des préférences,
- ✓ Filtrage par prix,
- ✓ Affichage des résultats

Description visuelle

L'interface est organisée pour guider l'utilisateur simplement du haut vers le bas : d'abord la saisie des préférences, puis le réglage du prix, enfin les résultats.




Figure 19: interface hôtel-IA

b- Exemple de recommandation :

Les recommandations sont présentées à l'utilisateur sous forme de liste, affichant les hôtels correspondant le mieux aux préférences spécifiées.

Après la saisie des informations nécessaires, les hôtels recommandés sont affichés avec des détails pertinents tels que :

- Le nom,
- L'adresse,
- Les caractéristiques des chambres,
- Les notes et les avis selon les sites booking et agoda,
- Les liens pour réserver.

The screenshot displays a web interface for hotel recommendations. On the left, a 'Filters' sidebar shows search criteria: Country (Netherlands), City (Amsterdam), Price Range (\$), and Amenities (air conditioning, desk, free wi-fi). The main content area, titled 'Recommended Hotels', features a card for 'Max Brown Hotel Canal District'. This card includes a 3-star rating, address (Herengracht 13-19), and price (\$71 / night). Below the card, ratings from Booking (8.0), Agoda (8.3), and the platform's own rating (8.2) are shown. A 'Reviews' section contains several user comments. At the bottom, a 'Book Now' section provides links to Booking and Agoda.

Filters

Country: Netherlands

City: Amsterdam

Price Range (\$): 50 - 209

Amenities: air conditioning, desk, free wi-fi

Recommended Hotels

Max Brown Hotel Canal District

★ **Star Rating: 3**

📍 **Address:** Herengracht 13-19

💰 **Price:** \$71 / night

Ratings:

Booking: 8.0 Agoda: 8.3 Our Rating: 8.2

Reviews:

- all good , we stayed for 4 nights 5 daya.
- Hotel was clean, good staff, good, but a little bit expensive for what it is.
- Very good
- The property's staff were friendly and the location was convenient and close to all the main things. However the value for money could be improved as the room was quite small and bathroom quite small too. Overall, it was a decent stay
- Disappointed

Book Now:

Booking Agoda

Figure 20: exemple de recommandation




Figure 21: 1er résultat de recommandation




Figure 22: 2ème résultat de recommandation

c- Valeur ajoutée :

Le développement de ce système de recommandation d'hôtels apporte plusieurs avantages significatifs, tant pour les utilisateurs que pour les prestataires de services hôteliers. Voici quelques-unes des principales valeurs ajoutées :

1. Amélioration de l'Expérience Utilisateur :

- **Personnalisation des Recommandations :** Le système utilise les préférences spécifiques des utilisateurs pour fournir des recommandations personnalisées. Cela permet aux utilisateurs de trouver plus rapidement et plus facilement des hôtels qui correspondent exactement à leurs besoins et à leurs attentes.
- **Réduction de la Surcharge d'Information :** En filtrant les options disponibles et en présentant uniquement les hôtels pertinents, le système aide les utilisateurs à éviter la surcharge d'informations souvent rencontrée lors de la recherche d'hôtels en ligne.

2. Augmentation de la Satisfaction et de la Fidélisation des Clients :

- **Recommandations Pertinentes :** En proposant des recommandations d'hôtels basées sur des caractéristiques spécifiques et des préférences personnelles, le système augmente la probabilité que les utilisateurs soient satisfaits de leur choix, ce qui peut se traduire par une fidélisation accrue.
- **Expérience de Recherche Simplifiée :** Une interface utilisateur intuitive et des fonctionnalités de filtrage et de tri avancées facilitent la recherche et la sélection d'hôtels, améliorant ainsi l'expérience globale des utilisateurs.

3. Optimisation des Revenus pour les Hôteliers :

- **Taux de Conversion Accru :** Des recommandations pertinentes et personnalisées augmentent la probabilité de réservation, ce qui peut entraîner une augmentation des revenus pour les hôteliers.
- **Visibilité Améliorée :** Les hôtels bien notés et correspondants aux préférences des utilisateurs obtiennent une meilleure visibilité, ce qui peut aider les établissements à attirer davantage de clients.

4. Efficacité et Gain de Temps :

- **Recherche Rapide :** Les utilisateurs peuvent rapidement trouver des hôtels qui répondent à leurs critères sans avoir à parcourir des listes interminables, ce qui leur fait gagner du temps.
- **Processus de Décision Simplifié :** Le système aide les utilisateurs à prendre des décisions informées en leur présentant des informations claires et pertinentes sur chaque hôtel recommandé.

CONCLUSION

Ce projet de développement d'un système de recommandation d'hôtels personnalisé basé sur le contenu a permis de mettre en œuvre une solution innovante et efficace pour répondre aux besoins spécifiques des utilisateurs dans le secteur hôtelier. Nous avons commencé par identifier l'importance cruciale des systèmes de recommandation dans divers domaines, en particulier pour améliorer l'expérience utilisateur et accroître la satisfaction et la fidélisation des clients dans l'industrie hôtelière.

La revue de la littérature a fourni un aperçu des différentes approches de recommandation existantes, notamment le filtrage collaboratif, les systèmes hybrides et les systèmes basés sur le contenu. Ces fondements théoriques ont été essentiels pour la conception de notre modèle, qui utilise la vectorisation TF-IDF pour transformer les caractéristiques textuelles des hôtels en vecteurs numériques, la similarité cosinus pour mesurer les similitudes entre les préférences des utilisateurs et les caractéristiques des hôtels, et le clustering K-Means pour regrouper les hôtels en clusters pertinents.

L'architecture du système a été soigneusement planifiée, incluant une interface utilisateur interactive et intuitive construite avec Streamlit. La persistance du modèle a été assurée par l'utilisation de Pickle, permettant ainsi de charger rapidement les modèles entraînés et de générer des recommandations en temps réel.

Les résultats obtenus démontrent que notre système de recommandation basé sur le contenu améliore significativement la pertinence des suggestions d'hôtels, répondant mieux aux préférences et besoins spécifiques des utilisateurs. L'analyse comparative avec d'autres approches de recommandation a confirmé les avantages de notre approche, notamment en termes de précision et de personnalisation des recommandations.

En termes de valeur ajoutée, ce projet contribue à une meilleure expérience utilisateur, augmente la satisfaction des clients et optimise les revenus pour les hôteliers. Les perspectives d'amélioration future incluent l'intégration de nouvelles sources de données, l'extension des fonctionnalités pour d'autres services de voyage, et l'amélioration continue des algorithmes de recommandation.

En conclusion, ce projet a démontré la faisabilité et l'efficacité d'un système de recommandation d'hôtels basé sur le contenu, offrant une solution pratique et innovante qui enrichit les pratiques dans le domaine des systèmes de recommandation tout en apportant une valeur tangible aux utilisateurs et aux prestataires de services hôteliers.

